

Trabalho N^o - Gradiente Normalizado e Least-square Normalizado

COE603 - Controle Adaptativo

Caio Cesar Leal Verissimo - 119046624

Leonardo Soares da Costa Tanaka - 121067652

Lincoln Rodrigues Proença - 121076407

Engenharia de Controle e Automação - UFRJ

Rio de Janeiro, Rio de Janeiro, Brasil

Junho de 2025

Conteúdo

1	Introdução	2
2	Descrição dos Algoritmos	2
2.1	Parametrização do Modelo	2
2.1.1	Definição dos sinais	2
2.1.2	Parâmetros e Regressor	3
2.1.3	Implementação do filtro	4
2.1.4	Adaptação	4
2.2	Gradiente Normalizado	5
2.2.1	Algoritmo:	5
2.2.2	Lema - Estabilidade do algoritmo do Gradiente:	5
2.3	Least-Squares Normalizado	7
2.3.1	Algoritmo:	7
2.3.2	Lema (Estabilidade do LS normalizado)	7
3	Simulações	10
4	Discussão dos Resultados	11

1 Introdução

Este trabalho visa a implementação de dois métodos de identificação adaptativa de parâmetros, o método do gradiente normalizado e o método dos mínimos quadrados. As próximas seções irão apresentar uma breve descrição dos algoritmos de cada método, os modelos de Simulink utilizados para as simulações, o resultado destas e uma discussão dos resultados.

2 Descrição dos Algoritmos

2.1 Parametrização do Modelo

Aqui serão apresentadas as parametrizações utilizadas para a obtenção dos algoritmos de adaptação.

2.1.1 Definição dos sinais

Seja uma planta de referência P , de entrada u e saída y . Admita-se também um módulo, Id , de identificação dos parâmetros θ como no diagrama de blocos abaixo:




Figura 1: Diagrama da Planta + Identificação

Escrevendo a planta P como $P(s)y = Z(s)u$, onde:

$$P(s) = s^n + \dots + p_1s + p_0$$

$$Z(s) = z_ms^m + \dots + z_1s + z_0$$

podemos definir um filtro:

$$\frac{1}{\Lambda(s)}$$

sendo $\Lambda(s) = s^n + \dots + \lambda_1s + \lambda_0$

para obter os sinais filtrados da entrada, $u_f, \dot{u}_f, \dots$ e da saída, $y_f, \dot{y}_f, \dots$

A nova estrutura pode ser representada no diagrama:




Figura 2: Diagrama da Planta + Filtros

Reescrevendo a equação da planta em função destes sinais:

$$\begin{aligned} \frac{P}{\Lambda}y &= \frac{Z}{\Lambda}u \\ \frac{P}{\Lambda}y &= \frac{Z}{\Lambda}u + \left(\frac{\Lambda}{\Lambda}y - y\right) \\ y &= \frac{Z}{\Lambda}u + \frac{\Lambda - P}{\Lambda}y \rightarrow y = Zu_f + (\Lambda - P)y_f \end{aligned}$$

é possível encontrar o sinal y em função dos sinais filtrados da planta.

2.1.2 Parâmetros e Regressor

Parametrização 1 Definindo o vetor de parâmetros, θ^* :

$$\theta^* = \begin{bmatrix} z_0 & z_1 & \cdots & z_m & (\lambda_0 - p_0) & (\lambda_1 - p_1) & \cdots & (\lambda_{n-1} - p_{n-1}) \end{bmatrix}^T$$

E o vetor regressor, ϕ :

$$\phi = \begin{bmatrix} u_f & \dot{u}_f & \ddot{u}_f & \cdots & y_f & \dot{y}_f & \ddot{y}_f & \cdots & y_f^{(n-1)} \end{bmatrix}^T$$

Concluimos que $y = \theta^{*T}\phi$

Parametrização 2 A partir da equação $Py = Zu$ e utilizando o filtro $\frac{1}{\Lambda}$, chegamos a uma outra parametrização:

$$\theta^* = \begin{bmatrix} z_0 & z_1 & \cdots & z_m & p_0 & p_1 & \cdots & p_{n-1} \end{bmatrix}^T$$

E:

$$\phi = \begin{bmatrix} u_f & \dot{u}_f & \ddot{u}_f & \cdots & u_f^{m-1} & -y_f & -\dot{y}_f & -\ddot{y}_f & \cdots & -y_f^{(n-1)} \end{bmatrix}^T$$

Parametrização 3 Uma terceira parametrização é possível, utilizando o vetor de parâmetros:

$$\theta^* = \left[\frac{1}{z_0} \quad \frac{-z_1}{z_0} \quad \frac{-z_2}{z_0} \quad \dots \quad \frac{-z_m}{z_0} \quad \frac{p_0}{z_0} \quad \frac{p_1}{z_0} \quad \dots \quad \frac{p_{n-1}}{z_0} \right]^T$$

E o vetor regressor:

$$\phi = \left[y_f^n \quad -\dot{u}_f \quad -\ddot{u}_f \quad \dots \quad -u_f^{m-1} \quad y_f \quad \dot{y}_f \quad \ddot{y}_f \quad \dots \quad y_f^{(n-1)} \right]^T$$

2.1.3 Implementação do filtro

Os filtros utilizados para os sinais de entrada e de saída são idênticos, seguindo a representação no espaço de estados:

$$\dot{\omega}_1 = A\omega_1 + bu$$

$$\dot{\omega}_2 = A\omega_2 + by$$

com as escolhas de A e b sendo:

$$A = \begin{bmatrix} 0 & 1 & 0 & \dots & 0 \\ 0 & 0 & 1 & \dots & 0 \\ \vdots & \ddots & \ddots & \ddots & \vdots \\ \lambda_0 & \lambda_1 & \lambda_2 & \dots & \lambda_{n-1} \end{bmatrix}, b = \begin{bmatrix} 0 \\ 0 \\ \vdots \\ 1 \end{bmatrix}$$

Essa configuração determina as saídas dos filtros como

$$\omega_1 = \begin{bmatrix} u_f \\ \dot{u}_f \\ \vdots \end{bmatrix}, \omega_2 = \begin{bmatrix} y_f \\ \dot{y}_f \\ \vdots \end{bmatrix}$$

para serem utilizadas nos modelos propostos.

2.1.4 Adaptação

Agora definimos $\theta(t)$ como uma estimativa de θ^* obtida por meio de um algoritmo Adaptativo. Temos:

- Estimativa de y : $\hat{y} = \theta^T \phi$
- Erro de estimativa: $\epsilon = \hat{y} - y$
- Erro paramétrico: $\tilde{\theta} = \theta - \theta^*$
- Portanto: $\epsilon = \tilde{\theta}^T \phi$

2.2 Gradiente Normalizado

2.2.1 Algoritmo:

O método do gradiente normalizado baseia-se na busca pelo mínimo de uma função custo percorrendo a direção negativa do gradiente. Definindo essa função custo como:

$$J(\theta) = \frac{\epsilon^2}{2m^2}$$

e o sinal normalizante:

$$m = 1 + \kappa \phi^T \phi, \kappa > 0$$

para que $\frac{\phi}{m}$ seja um sinal limitado.

Note que:

$$J(\theta) = \frac{\tilde{\theta}^T \phi \phi^T \tilde{\theta}}{2m^2}$$

O gradiente de J é dado por:

$$\frac{\partial J}{\partial \theta} = \frac{2\phi \phi^T \tilde{\theta}}{2m^2} = \frac{\phi \epsilon}{m^2}$$

O que nos leva a uma escolha para a dinâmica de θ :

$$\dot{\theta} = -\Gamma \frac{\phi \epsilon}{m^2}, \Gamma > 0$$

2.2.2 Lema - Estabilidade do algoritmo do Gradiente:

- $\theta \in \mathcal{L}_\infty$
- $\dot{\theta}, \epsilon_m \in \mathcal{L}_\infty \cap \mathcal{L}_2$

Prova

Função de Lyapunov candidata:

$$2V(\tilde{\theta}) = \tilde{\theta}^T \Gamma^{-1} \tilde{\theta}$$

Derivando:

$$\dot{V}(\tilde{\theta}) = \tilde{\theta}^T \Gamma^{-1} \dot{\tilde{\theta}} = \tilde{\theta}^T \Gamma^{-1} \left(-\frac{\Gamma \phi \epsilon}{m^2} \right) = -\frac{\epsilon^2}{m^2} = -\frac{(\tilde{\theta}^T \phi)^2}{m^2} \leq 0$$

Conclusões

- $\tilde{\theta} \in \mathcal{L}_\infty$
- $\frac{\epsilon}{m} \in \mathcal{L}_2$
- $\frac{\|\epsilon\|}{m} \leq \|\tilde{\theta}\| \frac{\|\phi\|}{m} \Rightarrow \frac{\|\epsilon\|}{m} \in \mathcal{L}_\infty$
- $\dot{\theta} = -\Gamma \frac{\phi}{m} \frac{\epsilon}{m} \Rightarrow \dot{\theta} \in \mathcal{L}_2 \cap \mathcal{L}_\infty$

Análise matricial

Note que:

$$\dot{\theta} = -\Gamma \frac{\phi \epsilon}{m^2}$$

$$A(t) = \frac{\Gamma \phi \phi^T}{m^2} = A^T(t) \geq 0, \quad \text{rank}(A(t)) = 1$$

onde:

$$\dot{\tilde{\theta}} = -A(t)\tilde{\theta}$$

★ Quer dizer, $\tilde{\theta} = 0$ é um ponto de equilíbrio uniformemente estável!!

Importante

- $\tilde{\theta} \equiv 0 \Rightarrow \epsilon = 0$
- $\epsilon = \tilde{\theta}^T \phi \equiv 0 \not\Rightarrow \tilde{\theta} = 0 \Rightarrow \tilde{\theta} \perp \phi$
- Se $\dot{\theta} \in \mathcal{L}_2 \cap \mathcal{L}_\infty$ e $\ddot{\theta} \in \mathcal{L}_\infty$, então:

$$\lim_{t \rightarrow \infty} \dot{\theta} = 0 \not\Rightarrow \theta \rightarrow \text{constante}$$

2.3 Least-Squares Normalizado

2.3.1 Algoritmo:

O LS normalizado é dado por

$$\dot{\theta}(t) = -\frac{P\phi\epsilon}{m^2}, \quad \theta(t_0) = \theta_0 \quad (1)$$

$$\dot{P} = -\frac{P\phi\phi^T P}{m^2}, \quad P(t_0) = P_0 > 0 \quad (2)$$

$$m^2 = 1 + \kappa \phi^T P \phi, \quad \kappa > 0. \quad (3)$$

Observação. $P(t)$ atua como um *ganho de adaptação* variante no tempo.

2.3.2 Lema (Estabilidade do LS normalizado)

Sob (1)–(2) valem:

1. $P(t) = P^T(t) > 0, \forall t.$
2. $P, \dot{P} \in \mathcal{L}_\infty.$
3. $\theta, \frac{\epsilon}{m}, \frac{\epsilon}{\bar{m}} \in \mathcal{L}_\infty$, onde $\bar{m}^2 = 1 + \phi^T P \phi.$
4. $\dot{\theta}, \frac{\epsilon}{m}, \frac{\epsilon}{\bar{m}} \in \mathcal{L}_2.$
5. $\lim_{t \rightarrow \infty} P(t) = P_\infty.$
6. $\lim_{t \rightarrow \infty} \theta(t) = \theta_\infty.$

Passo 1: $P(t)$ permanece s.d.p. e $P^{-1}(t)$ é monotonicamente crescente.

Como $P(t_0) > 0$, temos $P(t)P^{-1}(t) = I$. Derivando,

$$\dot{P} P^{-1} + P \frac{d}{dt} P^{-1} = 0 \Rightarrow \frac{d}{dt} P^{-1} = -P^{-1} \dot{P} P^{-1}.$$

Substituindo $\dot{P}$ de (2),

$$\frac{d}{dt} P^{-1} = -P^{-1} \left(-P \frac{\phi\phi^T}{m^2} P \right) P^{-1} = \frac{\phi\phi^T}{m^2} \geq 0.$$

Logo $P^{-1}(t)$ é monotonicamente crescente e, portanto, $P(t)$ é monotonicamente decrescente, permanecendo s.d.p. $\forall t$.

Passo 2: $P, \dot{P} \in \mathcal{L}_\infty.$

De $P(t) \downarrow$ e $P(t) > 0$, segue que $P(t)$ é limitado superiormente por $P(t_0)$, portanto $P \in \mathcal{L}_\infty$. Para $\dot{P}$, escreva $P = QQ^T$.

Então:

$$\dot{P} = -Q \frac{(Q\phi)(Q\phi)^T}{1 + \kappa \phi^T Q Q \phi} Q^T \Rightarrow \dot{P} \in \mathcal{L}_\infty.$$

Passo 3: Função de Lyapunov e $\tilde{\theta} \in \mathcal{L}_\infty$, $\epsilon_m \in \mathcal{L}_2$.

Considerando a seguinte função de Lyapunov:

$$V(\tilde{\theta}) = \tilde{\theta}^T P^{-1} \tilde{\theta}.$$

Derivando,

$$\begin{aligned} \dot{V} &= \dot{\theta}^T P^{-1} \tilde{\theta} + \tilde{\theta}^T \dot{P}^{-1} \tilde{\theta} + \tilde{\theta}^T P^{-1} \dot{\theta} \\ &= 2 \tilde{\theta}^T P^{-1} \dot{\theta} + \tilde{\theta}^T \left(-P^{-1} \dot{P} P^{-1} \right) \tilde{\theta} \\ &= 2 \tilde{\theta}^T P^{-1} \left(-\frac{P\phi\epsilon}{m^2} \right) - \tilde{\theta}^T P^{-1} \left(-\frac{P\phi\phi^T P}{m^2} \right) P^{-1} \tilde{\theta} \\ &= -\frac{2\epsilon^2}{m^2} + \frac{\epsilon^2}{m^2} = -\frac{\epsilon^2}{m^2} \leq 0. \end{aligned}$$

Isso implica que $\tilde{\theta} \in \mathcal{L}_\infty$. Além disso, $\dot{V} \leq 0$ implica $\frac{\epsilon}{m} \in \mathcal{L}_2$.

Passo 4: $\dot{\theta} \in L_2 \cap L_\infty$.

- $P \in \mathcal{L}_\infty \Rightarrow \frac{m}{m} \in \mathcal{L}_\infty$ ($P \rightarrow 0 \Rightarrow m \rightarrow 1$)
- $\frac{\epsilon}{m} = \tilde{\theta}^T \frac{\phi}{m} \Rightarrow \frac{\epsilon}{m} \in \mathcal{L}_\infty$
- $\frac{\epsilon}{m} = \frac{\epsilon}{m} \frac{m}{m} \Rightarrow \frac{\epsilon}{m} \in \mathcal{L}_2$
- $\frac{\epsilon}{m} = \frac{\epsilon}{m} \frac{m}{m} \Rightarrow \frac{\epsilon}{m} \in \mathcal{L}_\infty$
- $\dot{\theta} = -\frac{P\phi\epsilon}{m^2} = -Q \frac{Q\phi}{m} \frac{\epsilon}{m} \Rightarrow \dot{\theta} \in \mathcal{L}_2 \cap \mathcal{L}_\infty$

★ Note que pode ocorrer $P \rightarrow 0$ e $\phi \rightarrow \infty$; então $m \rightarrow 1$ e $\bar{m} \rightarrow \infty$. Nesse caso, sempre vale $\phi/\bar{m} \in \mathcal{L}_\infty$, mas $\phi/m \notin \mathcal{L}_\infty$.

Passo 5: Convergência de $P(t)$.

Integrando (2),

$$P(t) = P_0 - \int_{t_0}^t \frac{P\phi\phi^T P}{m^2} d\tau > 0,$$

Para todo z ,

$$z^T P z = z^T P_0 z - z^T I z > 0,$$

com $z^T I z$ monoticamente crescente e limitado por $z^T P_0 z$. Logo $z^T P z$ converge para algum $z^T P_\infty z \geq 0$, e portanto $\lim_{t \rightarrow \infty} P(t) = P_\infty$.

Passo 6: Expressão fechada de $\theta(t)$ e existência de θ_∞ .

Considere o funcional de custo LS normalizado

$$J(\theta) = \frac{1}{2} \int_{t_0}^t \frac{\varepsilon^2(\tau)}{m^2(\tau)} d\tau + \frac{1}{2} (\theta - \theta_0)^T P_0^{-1} (\theta - \theta_0).$$

onde $\varepsilon(\tau) = \theta^T(t)\phi(\tau) - y(\tau)$.

Anulando o gradiente, $\partial J/\partial \theta = 0$,

$$P_0^{-1}\theta(t) = P_0^{-1}\theta_0 - \int_{t_0}^t \frac{\phi\phi^T}{m^2} \theta(t) d\tau + \int_{t_0}^t \frac{y\phi}{m^2} d\tau.$$

Usando $P^{-1}(t) = P_0^{-1} + \int_{t_0}^t \frac{\phi\phi^T}{m^2} d\tau$, obtemos a forma explícita

$$\theta(t) = P \left(P_0^{-1}\theta_0 + \int_{t_0}^t \frac{y\phi}{m^2} d\tau \right).$$

Com $y = \phi^T \theta^*$,

$$\begin{aligned} \tilde{\theta} &= \theta(t) - \theta^* = P \left(P_0^{-1}\theta_0 + (P^{-1} - P_0^{-1})\theta^* \right) - \theta^* \\ &= P P_0^{-1}(\theta_0 - \theta^*) = P P_0^{-1}\tilde{\theta}(0). \end{aligned}$$

Equivalente e útil:

$$P^{-1}(t)\tilde{\theta}(t) = P_0^{-1}\tilde{\theta}(0) \quad (\text{constante!}).$$

Portanto,

$$\lim_{t \rightarrow \infty} \theta(t) = \theta^* + \lim_{t \rightarrow \infty} P(t)P_0^{-1}\tilde{\theta}(0) = \theta^* + P_\infty P_0^{-1}\tilde{\theta}(0)$$

Assim, obtendo:

$$\lim_{t \rightarrow \infty} \theta(t) = \theta_\infty$$

3 Simulações

4 Discussão dos Resultados

Os resultados obtidos ao longo das simulações demonstram o bom desempenho dos algoritmos de Gradiente Normalizado (NG) e Least-Square Normalizado (NLS) em cenários variados, apesar de limitações inerentes ao tempo finito de simulação e à estrutura dos sinais de entrada.

No **caso nominal**, observou-se que o erro converge para valores próximos de zero em todas as parametrizações, mantendo-se limitado ao longo do tempo. Contudo, a solução ótima de identificação não foi plenamente atingida, refletindo-se nos picos de erro que ocorrem nas transições da onda quadrada. Tais descontinuidades impõem desafios à adaptação, uma vez que o sistema precisa reagir rapidamente a mudanças bruscas na referência.

Com a **mudança do sinal de referência** para uma forma com componente senoidal, notou-se uma leve melhoria na resposta adaptativa, atribuída à maior riqueza espectral do sinal. Entretanto, essa melhoria não foi suficiente para garantir a convergência aos parâmetros ótimos. Além disso, o erro passou a apresentar um comportamento mais ruidoso, o que é esperado, já que fora dos ganhos ideais a planta tem maior dificuldade em acompanhar sinais com maior conteúdo em frequência.

Ao considerar o **aumento do ganho de adaptação**, identificou-se uma melhora significativa na rapidez de convergência e uma redução no valor absoluto do erro. No entanto, esse ganho mais elevado pode comprometer a robustez do sistema, especialmente quando combinado a outras condições, como estados iniciais não nulos ou perturbações, podendo levar a respostas instáveis ou imprevisíveis.

Por fim, a influência das **condições iniciais** manifestou-se principalmente como um pico inicial no erro, que, após um período de transiente, tende a decair e a seguir o comportamento do caso nominal. Esse fenômeno destaca a importância de uma análise criteriosa na escolha dos ganhos de adaptação, já que a atualização dos parâmetros identificados é diretamente influenciada pelo valor do erro, especialmente nos instantes iniciais de simulação.

De forma geral, os experimentos reforçam a sensibilidade dos algoritmos NG e NLS a características como a forma do sinal de referência, os ganhos de adaptação e as condições iniciais do sistema. Apesar das limitações observadas, ambos os métodos mostraram-se eficazes em promover a adaptação dos parâmetros em tempo real, mantendo o erro de seguimento sob controle.