

Trabalho N^o - Gradiente Normalizado e Least-square Normalizado

COE603 - Controle Adaptativo

Caio Cesar Leal Verissimo - 119046624

Leonardo Soares da Costa Tanaka - 121067652

Lincoln Rodrigues Proença - 121076407

Engenharia de Controle e Automação - UFRJ

Rio de Janeiro, Rio de Janeiro, Brasil

Junho de 2025

Conteúdo

1	Introdução	2
2	Descrição dos Algoritmos	2
2.1	Parametrização do Modelo	2
2.1.1	Definição dos sinais	2
2.1.2	Parâmetros e Regressor	3
2.1.3	Implementação do filtro	4
2.1.4	Adaptação	4
2.2	Gradiente Normalizado	5
2.3	Least-square Normalizado	5
3	Simulações	5
4	Discussão dos Resultados	6

1 Introdução

Este trabalho visa a implementação de dois métodos de identificação adaptativa de parâmetros, o método do gradiente normalizado e o método dos mínimos quadrados. As próximas seções irão apresentar uma breve descrição dos algoritmos de cada método, os modelos de Simulink utilizados para as simulações, o resultado destas e uma discussão dos resultados.

2 Descrição dos Algoritmos

2.1 Parametrização do Modelo

Aqui serão apresentadas as parametrizações utilizadas para a obtenção dos algoritmos de adaptação.

2.1.1 Definição dos sinais

Seja uma planta de referência P , de entrada u e saída y . Admita-se também um módulo, Id , de identificação dos parâmetros θ como no diagrama de blocos abaixo:




Figura 1: Diagrama da Planta + Identificação

Escrevendo a planta P como $P(s)y = Z(s)u$, onde:

$$P(s) = s^n + \dots + p_1s + p_0$$

$$Z(s) = z_ms^m + \dots + z_1s + z_0$$

podemos definir um filtro:

$$\frac{1}{\Lambda(s)}$$

, sendo $\Lambda(s) = s^n + \dots + \lambda_1s + \lambda_0$

para obter os sinais filtrados da entrada, $u_f, \dot{u}_f, \dots$ e da saída, $y_f, \dot{y}_f, \dots$

A nova estrutura pode ser representada no diagrama:




Figura 2: Diagrama da Planta + Identificação

Reescrevendo a equação da planta em função destes sinais:

$$\begin{aligned} \frac{P}{\Lambda}y &= \frac{Z}{\Lambda}u \\ \frac{P}{\Lambda}y &= \frac{Z}{\Lambda}u + \left(\frac{\Lambda}{\Lambda}y - y\right) \\ y &= \frac{Z}{\Lambda}u + \frac{\Lambda - P}{\Lambda}y \rightarrow y = Zu_f + (\Lambda - P)y_f \end{aligned}$$

é possível encontrar o sinal y em função dos sinais filtrados da planta.

2.1.2 Parâmetros e Regressor

Parametrização 1 Definindo o vetor de parâmetros, θ^* :

$$\theta^* = \begin{bmatrix} z_0 & z_1 & \cdots & z_m & (\lambda_0 - p_0) & (\lambda_1 - p_1) & \cdots & (\lambda_{n-1} - p_{n-1}) \end{bmatrix}^T$$

E o vetor regressor, ϕ :

$$\phi = \begin{bmatrix} u_f & \dot{u}_f & \ddot{u}_f & \cdots & y_f & \dot{y}_f & \ddot{y}_f & \cdots & y_f^{(n-1)} \end{bmatrix}^T$$

Concluimos que $y = \theta^{*T}\phi$

Parametrização 2 A partir da equação $Py = Zu$ e utilizando o filtro $\frac{1}{\Lambda}$, chegamos a uma outra parametrização:

$$\theta^* = \begin{bmatrix} z_0 & z_1 & \cdots & z_m & p_0 & p_1 & \cdots & p_{n-1} \end{bmatrix}^T$$

E:

$$\phi = \begin{bmatrix} u_f & \dot{u}_f & \ddot{u}_f & \cdots & u_f^{m-1} & -y_f & -\dot{y}_f & -\ddot{y}_f & \cdots & -y_f^{(n-1)} \end{bmatrix}^T$$

Parametrização 3 Uma terceira parametrização é possível, utilizando o vetor de parâmetros:

$$\theta^* = \left[\frac{1}{z_0} \quad \frac{-z_1}{z_0} \quad \frac{-z_2}{z_0} \quad \dots \quad \frac{-z_m}{z_0} \quad \frac{p_0}{z_0} \quad \frac{p_1}{z_0} \quad \dots \quad \frac{p_{n-1}}{z_0} \right]^T$$

E o vetor regressor:

$$\phi = \left[y_f^n \quad -\dot{u}_f \quad -\ddot{u}_f \quad \dots \quad -u_f^{m-1} \quad y_f \quad \dot{y}_f \quad \ddot{y}_f \quad \dots \quad y_f^{(n-1)} \right]^T$$

2.1.3 Implementação do filtro

Os filtros utilizados para os sinais de entrada e de saída são idênticos, seguindo a representação no espaço de estados:

$$\dot{\omega}_1 = A\omega_1 + bu$$

$$\dot{\omega}_2 = A\omega_2 + by$$

com as escolhas de A e b sendo:

$$A = \begin{bmatrix} 0 & 1 & 0 & \dots & 0 \\ 0 & 0 & 1 & \dots & 0 \\ \vdots & \ddots & \ddots & \ddots & \vdots \\ \lambda_0 & \lambda_1 & \lambda_2 & \dots & \lambda_{n-1} \end{bmatrix}, b = \begin{bmatrix} 0 \\ 0 \\ \vdots \\ 1 \end{bmatrix}$$

Essa configuração determina as saídas dos filtros como

$$\omega_1 = \begin{bmatrix} u_f \\ \dot{u}_f \\ \vdots \end{bmatrix}, \omega_2 = \begin{bmatrix} y_f \\ \dot{y}_f \\ \vdots \end{bmatrix}$$

para serem utilizadas nos modelos propostos.

2.1.4 Adaptação

Agora definimos $\theta(t)$ como uma estimativa de θ^* obtida por meio de um algoritmo Adaptativo. Temos:

Estimativa de y : $\hat{y} = \theta^T \phi$

Erro de estimativa: $\epsilon = \hat{y} - y$

Erro paramétrico: $\tilde{\theta} = \theta - \theta^*$

Portanto:

$$\epsilon = \tilde{\theta}^T \phi$$

2.2 Gradiente Normalizado

O método do gradiente normalizado baseia-se na busca pelo mínimo de uma função custo percorrendo a direção negativa do gradiente. Definindo essa função custo como

$$J(\theta) = \frac{\epsilon^2}{2m^2}$$

e o sinal normalizante

$$m = 1 + \kappa \phi^T \phi, \kappa > 0$$

para que $\frac{\phi}{m}$ seja um sinal limitado.

$J(\theta)$ pode ser reescrito como $\frac{\tilde{\theta}^T \phi \phi^T \tilde{\theta}}{2m^2}$

O gradiente de J é dado por

$$\frac{\partial J}{\partial \theta} = \frac{2\phi \phi^T}{2m^2} = \frac{\phi \epsilon}{m^2}$$

O que nos leva a uma escolha para a dinâmica de θ :

$$\dot{\theta} = -\Gamma \frac{\phi \epsilon}{m^2}, \Gamma > 0$$

2.3 Least-square Normalizado

3 Simulações

4 Discussão dos Resultados

Os resultados obtidos ao longo das simulações demonstram o bom desempenho dos algoritmos de Gradiente Normalizado (NG) e Least-Square Normalizado (NLS) em cenários variados, apesar de limitações inerentes ao tempo finito de simulação e à estrutura dos sinais de entrada.

No **caso nominal**, observou-se que o erro converge para valores próximos de zero em todas as parametrizações, mantendo-se limitado ao longo do tempo. Contudo, a solução ótima de identificação não foi plenamente atingida, refletindo-se nos picos de erro que ocorrem nas transições da onda quadrada. Tais discontinuidades impõem desafios à adaptação, uma vez que o sistema precisa reagir rapidamente a mudanças bruscas na referência.

Com a **mudança do sinal de referência** para uma forma com componente senoidal, notou-se uma leve melhoria na resposta adaptativa, atribuída à maior riqueza espectral do sinal. Entretanto, essa melhoria não foi suficiente para garantir a convergência aos parâmetros ótimos. Além disso, o erro passou a apresentar um comportamento mais ruidoso, o que é esperado, já que fora dos ganhos ideais a planta tem maior dificuldade em acompanhar sinais com maior conteúdo em frequência.

Ao considerar o **aumento do ganho de adaptação**, identificou-se uma melhora significativa na rapidez de convergência e uma redução no valor absoluto do erro. No entanto, esse ganho mais elevado pode comprometer a robustez do sistema, especialmente quando combinado a outras condições, como estados iniciais não nulos ou perturbações, podendo levar a respostas instáveis ou imprevisíveis.

Por fim, a influência das **condições iniciais** manifestou-se principalmente como um pico inicial no erro, que, após um período de transiente, tende a decair e a seguir o comportamento do caso nominal. Esse fenômeno destaca a importância de uma análise criteriosa na escolha dos ganhos de adaptação, já que a atualização dos parâmetros identificados é diretamente influenciada pelo valor do erro, especialmente nos instantes iniciais de simulação.

De forma geral, os experimentos reforçam a sensibilidade dos algoritmos NG e NLS a características como a forma do sinal de referência, os ganhos de adaptação e as condições iniciais do sistema. Apesar das limitações observadas, ambos os métodos mostraram-se eficazes em promover a adaptação dos parâmetros em tempo real, mantendo o erro de seguimento sob controle.