

Trabalho N^o 06 - LS-MRAC

COE603 - Controle Adaptativo

Caio Cesar Leal Verissimo - 119046624

Leonardo Soares da Costa Tanaka - 121067652

Lincoln Rodrigues Proença - 121076407

Engenharia de Controle e Automação - UFRJ

Rio de Janeiro, Rio de Janeiro, Brasil

Julho de 2025

Conteúdo

1	Descrição do Algoritmo	2
1.1	Revisão do M-MRAC	2
1.2	Introdução ao Algoritmo	3
1.2.1	Função de Lyapunov	3
1.2.2	Leis de Adaptação Propostas	3
1.3	Análise de Estabilidade	4
1.3.1	Condição de Estabilidade	4
1.3.2	Limitado de R e θ	4
1.3.3	Análise pela Função de Lyapunov	4
1.3.4	Convergência	5
1.4	Resumo do Algoritmo	5
2	Resultados das Simulações	6
2.1	Simulação #1 - Base	7
2.2	Simulação #2 - $y_0 = 10$	7
2.3	Simulação #3 - $\theta(0) = 0.9\theta^*$	8
2.4	Simulação #4 - $\gamma = 200$	8
2.5	Simulação #5 - $R(0) = 200I$	9
2.6	Simulação #6 - Mudança no Sinal de Referência	9
3	Discussão dos Resultados	10

1 Descrição do Algoritmo

1.1 Revisão do M-MRAC

Antes de apresentar o algoritmo proposto, revisamos o controlador adaptativo por modelo de referência M-MRAC, no qual o LS-MRAC é baseado.

A lei de controle considerada é:

$$u = \theta^T \omega + \dot{\tilde{\theta}}^T \xi$$

com:

$$L(s) = s + \ell_0, \quad \ell_0 > 0, \quad \text{e} \quad \xi = L^{-1}(s) \omega$$

O erro de rastreamento é definido por:

$$e_a = |k_p| M(s) L(s) [\theta^T \xi - \theta^{*T} \omega] = |k_p| M(s) L(s) [\tilde{\theta}^T \xi]$$

Assumindo que $M(s)L(s)$ pode ser decomposto como:

$$M(s)L(s) = \frac{s + \ell_0}{s + a_m} = \frac{\ell_0 - a_m}{s + a_m} + 1 = \alpha M(s) + 1, \quad \text{com } \ell_0 > a_m$$

Temos:

$$e_a = \alpha |k_p| M(s) [\tilde{\theta}^T \xi] + |k_p| [\tilde{\theta}^T \xi]$$

Assim, o sistema pode ser representado por:

$$\begin{cases} \dot{e} = A_m e + B_m [\tilde{\theta}^T \xi] \\ e_a = C_m e + |k_p| [\tilde{\theta}^T \xi] \end{cases}, \quad \text{com } e \in \mathbb{R}^{5n-2}$$

Utilizamos a seguinte função de Lyapunov:

$$2V = e^T Q e + \tilde{\theta}^T \Gamma^{-1} \tilde{\theta}$$

Derivando e reorganizando:

$$\dot{V} = -e^T Q e - |k_p| (\tilde{\theta}^T \xi)^2 + \tilde{\theta}^T [\xi e_a + \Gamma^{-1} \dot{\tilde{\theta}}]$$

Escolhendo a seguinte lei de adaptação:

$$\dot{\tilde{\theta}} = -\Gamma \xi e_a$$

Obtemos:

$$\dot{V} = -e^T Q e - |k_p| (\tilde{\theta}^T \xi)^2 \leq 0$$

Esse resultado garante que a função de Lyapunov é não crescente. Esta estrutura será estendida e refinada na próxima subseção, com a introdução do algoritmo LS-MRAC.

1.2 Introdução ao Algoritmo

Nesta seção, introduzimos o controlador adaptativo baseado no método dos mínimos quadrados (Least-Squares Model Reference Adaptive Control – LS-MRAC). Esse método é construído com base em uma função de Lyapunov que guia o projeto da lei de adaptação, visando garantir a estabilidade e a convergência do sistema.

1.2.1 Função de Lyapunov

Consideramos a seguinte função candidata de Lyapunov:

$$2V(e, \tilde{\theta}) = \gamma e^T P e + \tilde{\theta}^T R^{-1}(t) \tilde{\theta}, \quad \text{com } R(0) = R^T(0) > 0$$

Ao derivar essa função em relação ao tempo, obtemos:

$$\dot{V} = -\gamma e^T Q e - \gamma |k_p| (\tilde{\theta}^T \xi)^2 + \gamma \tilde{\theta}^T \xi e_a + \tilde{\theta}^T R^{-1} \dot{\tilde{\theta}} + \frac{1}{2} \tilde{\theta}^T \dot{R}^{-1} \tilde{\theta}$$

Lembrando que:

$$\frac{d}{dt}[RR^{-1}] = \dot{R}R^{-1} + R\dot{R}^{-1} = 0 \quad \Rightarrow \quad \dot{R}^{-1} = -R^{-1}\dot{R}R^{-1}$$

Substituindo na expressão de $\dot{V}$, temos:

$$\dot{V} = -\gamma e^T Q e - \gamma |k_p| (\tilde{\theta}^T \xi)^2 + \tilde{\theta}^T \left(\gamma \xi e_a + R^{-1} \dot{\tilde{\theta}} - \frac{1}{2} R^{-1} \dot{R} R^{-1} \tilde{\theta} \right)$$

1.2.2 Leis de Adaptação Propostas

Para garantir que a função de Lyapunov seja decrescente, propõe-se a seguinte lei de adaptação:

$$\begin{aligned} \dot{\tilde{\theta}} &= -\gamma R \xi e_a \\ \dot{R} &= -R \xi \xi^T R \end{aligned}$$

Com essa escolha, temos:

$$R^{-1} \dot{R} R^{-1} = -\xi \xi^T$$

E portanto:

$$\dot{V} = -\gamma e^T Q e - \gamma |k_p| (\tilde{\theta}^T \xi)^2 + \frac{1}{2} (\tilde{\theta}^T \xi)^2$$

Para garantir que $\dot{V} \leq 0$, é necessário que:

$$\gamma > \frac{1}{2|k_p|}$$

Essa condição será retomada e aprofundada na próxima subseção, dedicada à análise formal de estabilidade.

1.3 Análise de Estabilidade

Nesta subseção, analisamos a estabilidade do controlador adaptativo por mínimos quadrados (LS-MRAC).

1.3.1 Condição de Estabilidade

A condição para garantir a estabilidade do sistema é dada por:

$$\gamma > \frac{1}{2|k_p|}$$

Sob essa condição, valem as seguintes propriedades:

- $e \in \mathcal{L}_\infty$, $\tilde{\theta}^T R^{-1} \tilde{\theta} \in \mathcal{L}_\infty$
- $e \in \mathcal{L}_2$, $\tilde{\theta}^T \xi \in \mathcal{L}_2$
- $\omega, \xi, \dot{\xi} \in \mathcal{L}_\infty$

Consequentemente, a derivada da função de Lyapunov satisfaz:

$$\dot{V}(e, \tilde{\theta}) \leq 0$$

1.3.2 Limitado de R e θ

A limitação de R e θ é obtida como segue:

Sabemos que $R(0) = R^T(0) > 0$. Assim, ao integrar a equação de atualização de R^{-1} , obtemos:

$$\dot{R}^{-1}(t) = \xi \xi^T$$

$$R^{-1}(t) = R^{-1}(0) + J(t) > 0, \quad \forall t \geq 0$$

onde:

$$J(t) = \int_0^t \xi(\tau) \xi^T(\tau) d\tau$$

Portanto, $R^{-1}(t) > R^{-1}(0)$, o que implica que $R(t) > 0$ para todo $t \geq 0$, ou seja, $R \in \mathcal{L}_\infty$. Assim, $\dot{\theta}$ e $\dot{R}$ também pertencem a $\mathcal{L}_\infty$.

1.3.3 Análise pela Função de Lyapunov

A partir da função de Lyapunov:

$$2V = \gamma e^T P e + \tilde{\theta}^T R^{-1}(0) \tilde{\theta} + \tilde{\theta}^T J(t) \tilde{\theta}$$

Cada termo acima pertence a $\mathcal{L}_\infty$, portanto:

$$V \in \mathcal{L}_\infty \quad \Rightarrow \quad \tilde{\theta}^T R^{-1}(0) \tilde{\theta} \in \mathcal{L}_\infty \quad \Rightarrow \quad \tilde{\theta} \in \mathcal{L}_\infty$$

1.3.4 Convergência

- $\dot{e} \in \mathcal{L}_\infty \Rightarrow \lim_{t \rightarrow \infty} e(t) = 0$
- $\frac{d}{dt}(\tilde{\theta}^T \xi) \in \mathcal{L}_\infty \Rightarrow \lim_{t \rightarrow \infty} \tilde{\theta}^T \xi = 0$

Portanto, todos os sinais permanecem limitados, o que garante estabilidade global uniforme.

1.4 Resumo do Algoritmo

Subsistema	Equação	Ordem
Planta	$y = P(s) u$	n
Modelo	$y_m = M(s) r$	n
Erro de rastreamento	$e_a = \text{sign}(k_p)(y - y_m)$	
Filtros SV	$\dot{\omega}_1 = A_f \omega_1 + b_f u$ $\dot{\omega}_2 = A_f \omega_2 + b_f y$	$n - 1$
Regressor	$\omega^T = [\omega_1^T \ y \ \omega_2^T \ r]$	
Filtro ξ	$\xi = L^{-1}(s)[\omega]$	$2n$
Lei de controle	$u = \theta^T \omega + \dot{\theta}^T \xi$	
Lei de adaptação	$\dot{\theta} = -\gamma R \xi e_a, \quad \gamma > \frac{1}{2 k_p }$ $\dot{R} = -R \xi \xi^T R, \quad R(0) = R^T(0) > 0$	$2n$ $4n^2$

Tabela 1: Resumo dos subsistemas, equações e ordens do sistema adaptativo

Dimensão total do sistema: $N = 8n + 4n^2 - 2$

2 Resultados das Simulações

Nesta seção, são apresentados os resultados das simulações realizadas com o sistema adaptativo proposto. A estrutura da simulação foi mantida, variando-se apenas um parâmetro por vez em relação à simulação base. Dessa forma, torna-se possível analisar a sensibilidade e influência de cada parâmetro no desempenho do sistema.

As simulações consideram as seguintes definições de planta e modelo de referência:

- **Planta:** $P(s) = \frac{k_p(s+2)^2}{s^3}$, com $k_p = \frac{1}{3}$
- **Modelo de referência:** $M(s) = \frac{1}{s+1}$
- **Filtro auxiliar:** $\frac{1}{\Lambda(s)} = \frac{1}{(s+0.5)(s+1)(s+1.5)}$

A configuração de simulação base foi definida da seguinte forma:

- Ordem do sistema: $n = 3$
- Tempo final da simulação: $t_{\text{final}} = 100$ s
- Passo de simulação: $st = 0.01$ s
- Condições iniciais: $y_0 = 0$, $\theta_0 = \mathbf{0}_{6 \times 1}$
- $\gamma = 20$, $R(0) = 20I$
- Sinal de referência: $r(t) = 3 + 10sqw(0.1\pi t)$

A partir desta configuração base, foram realizadas as seguintes simulações adicionais:

- Condições iniciais com $y_0 = 10$
- Condições iniciais com $\theta(0) = 0,9 \cdot \theta^*$
- $\gamma = 200$
- Matriz $R(0) = 200I$
- Sinal de referência com componentes senoidais: $r(t) = 3 + 10sqw(0.1\pi t) + \sin(t) + \sin(3t) + \sin(5t)$

Os resultados serão discutidos a seguir, com gráficos de comparação entre a saída do sistema e o modelo, além das estimativas dos parâmetros adaptativos e da evolução dos erros. Cada simulação destacará o impacto da variação considerada sobre o comportamento geral do sistema.

2.1 Simulação #1 - Base




Figura 1: Resultados da Simulação #1

2.2 Simulação #2 - $y_0 = 10$




Figura 2: Resultados da Simulação #2

2.3 Simulação #3 - $\theta(0) = 0.9\theta^*$




Figura 3: Resultados da Simulação #3

2.4 Simulação #4 - $\gamma = 200$




Figura 4: Resultados da Simulação #4

2.5 Simulação #5 - $R(0) = 200I$




Figura 5: Resultados da Simulação #5

2.6 Simulação #6 - Mudança no Sinal de Referência




Figura 6: Resultados da Simulação #6

3 Discussão dos Resultados

Nesta seção são analisados os comportamentos observados nas simulações do controlador LS-MRAC, com foco em robustez, velocidade de adaptação e sensibilidade a parâmetros.

Simulação #1 – Base: O sistema acompanha a referência $y_m(t)$ com erro $e_a \rightarrow 0$ e convergência suave dos parâmetros $\theta(t)$, validando estabilidade global uniforme.

Simulação #2 – $y_0 = 10$: Perturbação inicial gera transiente acentuado, mas o rastreamento é rapidamente recuperado, demonstrando robustez frente a condições iniciais desfavoráveis.

Simulação #3 – $\theta(0) = 0,9\theta^*$: Parâmetros próximos do ideal aceleram a convergência, com redução do erro e transiente mais curto. Boa estimativa inicial melhora desempenho, embora não seja essencial.

Simulação #4 – $\gamma = 200$: Aumento do ganho de adaptação acelera a convergência, mas eleva a sensibilidade a ruídos. Há um compromisso entre rapidez e robustez.

Simulação #5 – $R(0) = 200I$: Valor inicial elevado para R reduz a agressividade inicial do estimador, resultando em adaptação mais conservadora, mas ainda convergente.

Simulação #6 – Referência Senoidal: A introdução de componentes senoidais melhora a persistência de excitação, promovendo convergência mais clara e erro pequeno, mesmo com maior complexidade no sinal.

Conclusão: As simulações confirmam os fundamentos do LS-MRAC: estabilidade, rastreamento preciso e adaptação eficaz. O sistema é robusto a variações iniciais e seus parâmetros podem ser ajustados para melhorar desempenho sem comprometer a estabilidade.