

Trabalho N^o 07 - Combined M-MRAC + LS

COE603 - Controle Adaptativo

Caio Cesar Leal Verissimo - 119046624

Leonardo Soares da Costa Tanaka - 121067652

Lincoln Rodrigues Proença - 121076407

Engenharia de Controle e Automação - UFRJ

Rio de Janeiro, Rio de Janeiro, Brasil

Julho de 2025

Conteúdo

1	Estabilidade do algoritmo Combined MRAC - Caso de Primeira Ordem	3
1.1	Modelo da Planta e do Modelo de Referência	3
1.2	Estimador Composto M-MRAC + LS	3
1.3	Leis de Atualização	4
1.4	Reescrevendo as Funções Δ	5
1.5	Análise de Estabilidade pelo Método de Lyapunov	5
1.6	Conclusão sobre Estabilidade	6
2	Descrição do Algoritmo	6
2.1	Introdução do Algoritmo	6
2.2	Análise de Estabilidade	7
2.2.1	Algoritmo LS Proposto	8
2.2.2	Procedimento de Projeto	8
2.2.3	Conclusões da Análise	9
2.2.4	Convergência dos Erros	10
2.3	Resumo do Algoritmo	11
3	Resultados das Simulações	11
3.1	Simulação #1 - Base	13
3.2	Simulação #2 - $y_0 = 10$	13
3.3	Simulação #3 - $\theta(0) = 0.9\theta^*$	14
3.4	Simulação #4 - $R(0) = 2I$	14
3.5	Simulação #5 - $\gamma = 50$	15
3.6	Simulação #6 - $\tau = 50$	15
3.7	Simulação #7 - $\beta = 1$	16
3.8	Simulação #8 - $\kappa = 0.01$	16
3.9	Simulação #9 - $\sigma = 0.05$	17
3.10	Simulação #10 - $\alpha = 100$	17
3.11	Simulação #11 - Mudança no Sinal de Referência	18
4	Discussão dos Resultados	18

1 Estabilidade do algoritmo Combined MRAC - Caso de Primeira Ordem

1.1 Modelo da Planta e do Modelo de Referência

Considera-se uma planta de primeira ordem com dinâmica dada por:

$$\dot{y} = -a_p y + k_p u \quad (1)$$

O modelo de referência, que define o comportamento desejado para a saída, é dado por:

$$\dot{y}_m = -a_m y_m + k_m r, \quad a_m > 0 \quad (2)$$

O erro de rastreamento entre a planta e o modelo é definido como:

$$e = y - y_m \quad (3)$$

Define-se o vetor regressor como:

$$\omega = \begin{bmatrix} y & r \end{bmatrix}^T \quad (4)$$

E os parâmetros estimados de controle como:

$$\theta = \begin{bmatrix} \theta_1 & \theta_2 \end{bmatrix}^T \quad (5)$$

A lei de controle adotada é linear em relação ao vetor regressor e definida por:

$$u = \theta^T \omega \quad (6)$$

Os parâmetros ideais correspondentes são obtidos de forma a garantir que o erro de rastreamento vá a zero quando usados na lei de controle:

$$\theta_1^* = \frac{a_p - a_m}{k_p} \quad (7)$$

$$\theta_2^* = \frac{k_m}{k_p} \quad (8)$$

1.2 Estimador Composto M-MRAC + LS

Para complementar o algoritmo, é incluído um estimador dos parâmetros da planta. Os parâmetros estimados da planta são representados por:

$$\psi = \begin{bmatrix} \psi_1 & \psi_2 \end{bmatrix}^T \quad (9)$$

E os valores ideais desses parâmetros são:

$$\psi^* = \begin{bmatrix} a_p & k_p \end{bmatrix}^T \quad (10)$$

O modelo de identificação proposto para estimar a saída da planta é:

$$\dot{\hat{y}} = -a_i \epsilon - \psi_1 y + \psi_2 u, \quad a_i > 0 \quad (11)$$

Com o erro de identificação definido como a diferença entre a saída real e a saída estimada:

$$\epsilon = y - \hat{y} \quad (12)$$

Com base nas equações do modelo, estabelecem-se as seguintes relações algébricas entre os parâmetros ideais:

$$\psi_2^* \theta_1^* - \psi_1^* + a_m = 0 \quad (13)$$

$$\psi_2^* \theta_2^* - k_m = 0 \quad (14)$$

Com isso, definem-se as expressões dos erros não lineares:

$$\Delta_1 = \psi_2 \theta_1 - \psi_1 + a_m \quad (15)$$

$$\Delta_2 = \psi_2 \theta_2 - k_m \quad (16)$$

$$\dot{e} = -a_m e + k_p \tilde{\theta}^T \omega \quad (17)$$

Além disso, a equação dinâmica do erro de identificação é dada por:

$$\dot{\epsilon} = -a_i \epsilon - \tilde{\psi}_1 y + \tilde{\psi}_2 u \quad (18)$$

1.3 Leis de Atualização

A lei de adaptação dos parâmetros de controle é definida da seguinte forma:

$$\dot{\theta} = -\text{sign}(k_p)[\gamma_1 e \omega + \gamma_2 \Delta] \quad (19)$$

E a atualização dos parâmetros da planta é feita por:

$$\dot{\psi}_1 = \kappa_1 \epsilon y + \kappa_2 \Delta_1 \quad (20)$$

$$\dot{\psi}_2 = -\kappa_1 \epsilon u - \kappa_2 \theta^T \Delta \quad (21)$$

1.4 Reescrevendo as Funções Δ

As expressões para os termos Δ_1 e Δ_2 podem ser reescritas com base nos parâmetros de erro:

$$\Delta_1 = \psi_2 \theta_1 - \psi_1 + a_m - (\psi_2^* \theta_1^* - \psi_1^* + a_m) \quad (22)$$

$$= \theta_1 \tilde{\psi}_2 - \tilde{\psi}_1 + k_p \tilde{\theta}_1 \quad (23)$$

$$\Delta_2 = \psi_2 \theta_2 - k_m - (\psi_2^* \theta_2^* - k_m) \quad (24)$$

$$= \theta_2 \tilde{\psi}_2 + k_p \tilde{\theta}_2 \quad (25)$$

1.5 Análise de Estabilidade pelo Método de Lyapunov

Para analisar a estabilidade do sistema, considera-se a seguinte função de Lyapunov candidata:

$$V = \frac{\gamma_1}{2\gamma_2} e^2 + \frac{|k_p|}{2\gamma_2} \tilde{\theta}^T \tilde{\theta} + \frac{\kappa_1}{2\kappa_2} \epsilon^2 + \frac{1}{2\kappa_2} \tilde{\psi}^T \tilde{\psi} \quad (26)$$

Cada termo é um quadrado ponderado por constantes positivas, portanto V é positiva definida.

Derivando a função V no tempo:

$$\dot{V} = \frac{\gamma_1}{\gamma_2} e \dot{e} + \frac{|k_p|}{\gamma_2} \tilde{\theta}^T \dot{\tilde{\theta}} + \frac{\kappa_1}{\kappa_2} \epsilon \dot{\epsilon} + \frac{1}{\kappa_2} \tilde{\psi}^T \dot{\tilde{\psi}} \quad (27)$$

Substituindo as dinâmicas de erro e leis de adaptação:

Para o erro de rastreamento:

$$\dot{e} = -a_m e + k_p \tilde{\theta}^T \omega \quad (28)$$

$$\Rightarrow \frac{\gamma_1}{\gamma_2} e \dot{e} = -\frac{\gamma_1}{\gamma_2} a_m e^2 + \frac{\gamma_1}{\gamma_2} k_p e \tilde{\theta}^T \omega \quad (29)$$

Para a atualização de θ :

$$\dot{\tilde{\theta}} = -\text{sign}(k_p) [\gamma_1 e \omega + \gamma_2 \Delta] \quad (30)$$

$$\Rightarrow \frac{|k_p|}{\gamma_2} \tilde{\theta}^T \dot{\tilde{\theta}} = -\frac{\gamma_1}{\gamma_2} k_p e \tilde{\theta}^T \omega - k_p \tilde{\theta}^T \Delta \quad (31)$$

Para o erro de identificação:

$$\dot{\epsilon} = -a_i \epsilon - \tilde{\psi}_1 y + \tilde{\psi}_2 u \quad (32)$$

$$\Rightarrow \frac{\kappa_1}{\kappa_2} \epsilon \dot{\epsilon} = -\frac{\kappa_1}{\kappa_2} a_i \epsilon^2 - \frac{\kappa_1}{\kappa_2} \epsilon \tilde{\psi}_1 y + \frac{\kappa_1}{\kappa_2} \epsilon \tilde{\psi}_2 u \quad (33)$$

Para a atualização dos parâmetros da planta:

$$\frac{1}{\kappa_2} \tilde{\psi}^T \dot{\tilde{\psi}} = \frac{\kappa_1}{\kappa_2} \epsilon \tilde{\psi}_1 y + \tilde{\psi}_1 \Delta_1 - \frac{\kappa_1}{\kappa_2} \epsilon \tilde{\psi}_2 u - \tilde{\psi}_2 \theta^T \Delta \quad (34)$$

Agrupando os termos:

$$\dot{V} = -\frac{\gamma_1}{\gamma_2} a_m e^2 - \frac{\kappa_1}{\kappa_2} a_i \epsilon^2 - k_p \tilde{\theta}^T \Delta + \tilde{\psi}_1 \Delta_1 - \tilde{\psi}_2 \theta^T \Delta \quad (35)$$

E reconhecendo que os termos restantes formam um quadrado:

$$-k_p \tilde{\theta}^T \Delta + \tilde{\psi}_1 \Delta_1 - \tilde{\psi}_2 \theta^T \Delta = -\Delta^T \Delta \quad (36)$$

Conclui-se que a derivada de V é:

$$\dot{V} = -\frac{\gamma_1}{\gamma_2} a_m e^2 - \frac{\kappa_1}{\kappa_2} a_i \epsilon^2 - \Delta^T \Delta \leq 0 \quad (37)$$

1.6 Conclusão sobre Estabilidade

Como a derivada de V é negativa semi-definida, pelo Teorema de Lyapunov Direto, o sistema é estável no sentido de Lyapunov.

Observação final: Para garantir a convergência assintótica dos erros, aplica-se o Teorema de LaSalle. Como $\dot{V} = 0$ implica que $e = 0$, $\epsilon = 0$ e $\Delta = 0$, sob a hipótese de persistência de excitação, os parâmetros estimados convergem para os seus valores ideais.

2 Descrição do Algoritmo

2.1 Introdução do Algoritmo

O algoritmo M-MRAC + LS tem como motivação o fato de que, se o erro de controle $\tilde{u} \approx 0$, então:

$$u = \theta^{*T} \omega + \tilde{u} \Rightarrow u \approx \theta^{*T} \omega \quad (38)$$

Dessa forma, é possível aplicar um algoritmo de mínimos quadrados (LS) para estimar diretamente o vetor de parâmetros θ^* a partir da medida da entrada u .

O diagrama em blocos do algoritmo combinado M-MRAC com LS é apresentado na Figura 1, onde ψ representa uma segunda estimativa para os parâmetros θ^* , fornecida pelo estimador LS.




Figura 1: Diagrama em blocos do estimador combinado M-MRAC + LS

O problema principal consiste em projetar um algoritmo de estimação combinado que seja estável.

Recordando a equação do erro de adaptação:

$$e_a = \alpha |k_p| M(s) [\tilde{\theta}^T \xi] + |k_p| [\tilde{\theta}^T \xi] \quad (39)$$

Esse sistema, composto pela planta e pelos filtros, tem ordem total igual a $5n - 2$. A realização em espaço de estados não mínima é dada por:

$$\begin{cases} \dot{e} = A_m e + B_m [\tilde{\theta}^T \xi] \\ e_a = C_m e + |k_p| [\tilde{\theta}^T \xi] \end{cases} \quad (40)$$

Pelo Lema de Kalman-Yakubovich (MKY), se o sistema $\{A_m, B_m, C_m\}$ é SPR (strictly positive real), então existe duas matrizes simétricas definidas positivas $P = P^T > 0$ e $Q = Q^T > 0$ tal que:

$$\begin{cases} A_m^T P + P A_m = -2Q, \\ P B_m = C_m^T \end{cases} \quad (41)$$

2.2 Análise de Estabilidade

O algoritmo combinado propõe uma nova lei de adaptação para θ , incorporando a estimativa LS ψ :

$$\dot{\theta} = -\Gamma \xi e_a - \sigma \Delta, \quad \Gamma = \Gamma^T > 0, \quad \sigma > 0 \quad (42)$$

onde:

$$\Delta = \theta - \psi \quad (43)$$

Quando $e_a \equiv 0$, temos:

$$\dot{\theta} = -\sigma(\theta - \psi) \quad \Rightarrow \quad \theta = \frac{1}{(1/\sigma)s + 1} \psi \quad (44)$$

Ou seja, θ segue ψ com constante de tempo igual a $1/\sigma$.

A parametrização linear é obtida reescrevendo-se o erro:

$$\frac{1}{k_p} e_0 = M(s)[u] - \theta^{*T} M(s)[\omega] \quad (45)$$

Aplicando $M^{-1}(s)L^{-1}(s)$ em ambos os lados:

$$\frac{1}{k_p} M^{-1} L^{-1}[e_0] = L^{-1}[u] - \theta^{*T} L^{-1}[\omega], \quad (46)$$

isso é:

$$\zeta = \theta^{*T} \xi + \theta_{2n}^* M^{-1} L^{-1}[e_0] \quad (47)$$

Com a decomposição:

$$M^{-1}(s)L^{-1}(s) = -(\ell_0 - a_m)L^{-1}(s) + 1 \quad (48)$$

Obtemos:

$$\zeta = \theta^{*T} \left(\xi + \begin{bmatrix} 0 \\ e_0 - \alpha\varphi \end{bmatrix} \right) = \theta^{*T} \phi \quad (49)$$

Sendo:

$$\varphi = L^{-1}(s)[e_0], \quad \phi = \xi + \begin{bmatrix} 0 \\ e_0 - \alpha\varphi \end{bmatrix} \quad (50)$$

2.2.1 Algoritmo LS Proposto

A nova estimativa ψ segue a estrutura:

$$\hat{\zeta} = \psi^T \phi \quad (51)$$

$$\varepsilon = \zeta - \hat{\zeta} = (\psi - \theta^*)^T \phi = \tilde{\psi}^T \phi \quad (52)$$

Com as seguintes leis de atualização:

$$\dot{\psi} = -R \left(\frac{\tau \phi \varepsilon}{m^2} - \frac{\sigma}{\beta} \Gamma^{-1} \Delta \right), \quad \tau \geq \frac{1}{2}, \beta > 0 \quad (53)$$

$$\dot{R} = -\frac{R \phi \phi^T R}{m^2}, \quad R(0) = R^T(0) > 0 \quad (54)$$

$$m^2 = 1 + \kappa \phi^T R \phi, \quad \kappa > 0 \quad (55)$$

2.2.2 Procedimento de Projeto

A função de Lyapunov considerada para o sistema combinado é dada por:

$$2V(e, \tilde{\theta}, \tilde{\psi}) = e^T P e + \tilde{\theta}^T \Gamma^{-1} \tilde{\theta} + \beta \tilde{\psi}^T R^{-1}(t) \tilde{\psi} \quad (56)$$

Derivando essa função em relação ao tempo:

$$\dot{V} = -e^T Q e + e^T P B_m \tilde{\theta}^T \xi + \tilde{\theta}^T \Gamma^{-1} \dot{\tilde{\theta}} + \beta \tilde{\psi}^T R^{-1} \dot{\tilde{\psi}} - \frac{1}{2} \beta \tilde{\psi}^T R^{-1} \dot{R} R^{-1} \tilde{\psi} \quad (57)$$

Sabemos que:

$$e^T P B_m = e^T C_m^T = e_a - |k_p| \tilde{\theta}^T \xi \quad (58)$$

Substituindo essa relação na equação da derivada:

$$\dot{V} = -e^T Q e - |k_p| (\tilde{\theta}^T \xi)^2 + \tilde{\theta}^T [\xi e_a + \Gamma^{-1} \dot{\tilde{\theta}}] + \beta \tilde{\psi}^T R^{-1} \dot{\tilde{\psi}} - \frac{1}{2} \beta \tilde{\psi}^T R^{-1} \dot{R} R^{-1} \tilde{\psi} \quad (59)$$

Utilizando as leis de atualização de $\dot{\theta}, \dot{\psi}, \dot{R}$, obtemos:

$$\dot{V} = -e^T Q e - |k_p|(\tilde{\theta}^T \xi)^2 - \sigma \tilde{\theta}^T \Gamma^{-1} \Delta - \beta \tilde{\psi}^T \left(\frac{\tau \phi \phi^T \tilde{\psi}}{m^2} - \frac{\sigma}{\beta} \Gamma^{-1} \Delta \right) + \frac{1}{2} \beta \tilde{\psi}^T \frac{\phi \phi^T}{m_2} \tilde{\psi} \quad (60)$$

$$= -e^T Q e - |k_p|(\tilde{\theta}^T \xi)^2 - \sigma(\tilde{\theta} - \tilde{\psi})^T \Gamma^{-1}(\tilde{\theta} - \tilde{\psi}) - \frac{\beta}{2m^2}(2\tau - 1)(\tilde{\psi}^T \phi)^2 \quad (61)$$

Como $\Delta = \theta - \psi = \tilde{\theta} - \tilde{\psi}$, o termo cruzado pode ser reescrito de forma a garantir que todos os termos são negativos definidos ou semi-definidos.

Portanto, a derivada de Lyapunov é dada por:

$$\dot{V} = -e^T Q e - |k_p|(\tilde{\theta}^T \xi)^2 - \sigma \Delta^T \Gamma^{-1} \Delta - \frac{\beta}{2m^2}(2\tau - 1)\varepsilon^2 \quad (62)$$

Sob a condição de projeto $\tau > 1/2$, garantimos que $\dot{V} \leq 0$, assegurando a estabilidade do sistema no sentido de Lyapunov.

2.2.3 Conclusões da Análise

A condição de estabilidade para o algoritmo proposto é que $\tau > \frac{1}{2}$. Sob essa condição, temos:

- $\dot{V}(e, \tilde{\theta}, \tilde{\psi}) \leq 0$, garantindo que $e, \theta \in \mathcal{L}_\infty$, bem como $\tilde{\psi}^T R^{-1} \tilde{\psi} \in \mathcal{L}_\infty$.
- Os sinais $e, \tilde{\theta}^T \xi, \Delta, \varepsilon \in \mathcal{L}_2$.
- Como $e \in \mathcal{L}_\infty$, então $\omega, \xi, \dot{\xi}, \varphi, \dot{\varphi} \in \mathcal{L}_\infty$.
- $\theta, \xi \in \mathcal{L}_\infty \Rightarrow \dot{e} \in \mathcal{L}_\infty$.
- $e, \dot{e}, \xi, \dot{\xi} \in \mathcal{L}_\infty \Rightarrow \phi, \dot{\phi} \in \mathcal{L}_\infty$

Sabemos que $R(0) = R^T(0) > 0$. Integrando a derivada de $R^{-1}(t)$, temos:

$$\dot{R}^{-1}(t) = \phi \phi^T \geq 0 \Rightarrow R^{-1}(t) = R^{-1}(0) + \int_0^t \phi(\tau) \phi^T(\tau), \quad t \geq 0 \quad (63)$$

Com isso, segue que:

- $R^{-1}(t) > R^{-1}(0)$, ou seja, cresce monotonicamente.
- $R(t) > 0, \forall t \geq 0$, ou seja, $R(t)$ decresce monotonicamente.
- $R \in \mathcal{L}_\infty$.
- Como $R, \phi \in \mathcal{L}_\infty$, então $\dot{R} \in \mathcal{L}_\infty$.

A partir da função de Lyapunov:

$$2V = e^T P e + \tilde{\theta}^T \Gamma^{-1} \tilde{\theta} + \beta \tilde{\psi}^T R^{-1}(0) \tilde{\psi} + \beta \tilde{\psi}^T J(t) \tilde{\psi} \quad (64)$$

Concluimos que:

- $V \in \mathcal{L}_\infty \Rightarrow \tilde{\psi}^T R^{-1}(0) \tilde{\psi} \in \mathcal{L}_\infty \Rightarrow \tilde{\psi} \in \mathcal{L}_\infty.$
- $\tilde{\psi} \in \mathcal{L}_\infty \Rightarrow \hat{\zeta}, \Delta, \dot{\theta} \in \mathcal{L}_\infty.$
- $\dot{\theta} \in \mathcal{L}_\infty \Rightarrow u \in \mathcal{L}_\infty.$
- $u \in \mathcal{L}_\infty \Rightarrow \zeta, \dot{\zeta} \in \mathcal{L}_\infty.$
- $\zeta, \dot{\zeta} \in \mathcal{L}_\infty \Rightarrow \varepsilon \in \mathcal{L}_\infty.$
- $\varepsilon \in \mathcal{L}_\infty \Rightarrow \dot{\psi}, \dot{\Delta} \in \mathcal{L}_\infty.$

2.2.4 Convergência dos Erros

- Como $\dot{e} \in \mathcal{L}_\infty \Rightarrow \lim_{t \rightarrow \infty} e(t) = 0.$
- Como $\frac{d}{dt} \tilde{\theta}^T \xi \in \mathcal{L}_\infty \Rightarrow \lim_{t \rightarrow \infty} \tilde{\theta}^T \xi = 0.$
- Como $\dot{\Delta} \in \mathcal{L}_\infty \Rightarrow \lim_{t \rightarrow \infty} \Delta(t) = 0.$
- Como $\dot{\varepsilon} = \frac{d}{dt} (\tilde{\psi}^T \phi) \in \mathcal{L}_\infty \Rightarrow \lim_{t \rightarrow \infty} \varepsilon = 0.$

Portanto, todos os sinais são limitados e os erros convergem para zero. Isso garante estabilidade global uniforme.

Observação: Para valores grandes de β , o termo $\frac{\sigma}{\beta} \Gamma^{-1} \Delta$ torna-se desprezível, desacoplando a equação de atualização de $\dot{\psi}$ da dinâmica de θ .

2.3 Resumo do Algoritmo

Subsistema	Equação	Ordem
Planta	$y = P(s)u$	n
Modelo	$y_m = M(s)r$	n
Erro de rastreamento	$e_a = \text{sign}(k_p)(y - y_m)$	
Filtros SV	$\dot{\omega}_1 = A_f \omega_1 + b_f u$ $\dot{\omega}_2 = A_f \omega_2 + b_f y$	$n - 1$
Regressor	$\omega^T = [\omega_1^T \quad y \quad \omega_2^T \quad r]$	
Filtro ξ	$\dot{\xi} = -\ell_0 \xi + \omega, \quad \ell_0 > a_m$	$2n$
Lei de controle	$u = \theta^T \omega + \dot{\theta}^T \xi$	
Lei de adaptação	$\dot{\theta} = -\Gamma \xi e_a - \sigma \Delta, \quad \Gamma = \Gamma^T > 0, \quad \sigma > 0$ $\Delta = \theta - \psi$	$2n$
Filtros auxiliares	$\dot{\zeta} = -\ell_0 \zeta + u$ $\dot{\varphi} = -\ell_0 \varphi + e_0$	1
Predição	$\hat{\zeta} = \psi^T \phi$ $\phi = \xi + [\mathbf{0}^T \quad (e_0 - \alpha \varphi)]^T, \quad \mathbf{0} \in \mathbb{R}^{2n-1}$	
Erro de predição	$\varepsilon = \hat{\zeta} - \zeta$	
Estimador LS	$\dot{\psi} = -R \left(\tau \phi \varepsilon - \frac{\sigma}{\beta} \Gamma^{-1} \Delta \right), \quad \tau > \frac{1}{2}, \quad \beta > 0$ $\dot{R} = -\frac{R \phi \phi^T R}{m^2}, \quad R(0) = R^T(0) > 0$ $m^2 = 1 + \kappa \phi^T R \phi, \quad \kappa \geq 0$	$2n$ $4n^2$

Tabela 1: Resumo dos subsistemas, equações e ordens no controle adaptativo

Dimensão total do sistema: $N = 10n + 4n^2$

3 Resultados das Simulações

Nesta seção, são apresentados os resultados das simulações realizadas com o sistema adaptativo proposto. A estrutura da simulação foi mantida, variando-se apenas um parâmetro por vez em relação à simulação base. Dessa forma, torna-se possível analisar a sensibilidade e influência de cada parâmetro no desempenho do sistema.

As simulações consideram as seguintes definições de planta e modelo de referência:

- **Planta:** $P(s) = \frac{k_p(s+2)^2}{s^3}$, com $k_p = \frac{1}{3}$
- **Modelo de referência:** $M(s) = \frac{1}{s+1}$
- **Filtro auxiliar:** $\frac{1}{\Lambda(s)} = \frac{1}{(s+0.5)(s+1)(s+1.5)}$

A configuração de simulação base foi definida da seguinte forma:

- Ordem do sistema: $n = 3$
- Tempo final da simulação: $t_{\text{final}} = 80$ s

- Passo de simulação: $\Delta t = 0.01$ s
- Condições iniciais: $y_0 = 0$, $\theta_0 = \mathbf{0}_{6 \times 1}$
- $\gamma = 5$, $R(0) = 200I$
- $\tau = 5$, $\beta = 1000$, $\kappa = 0.1$, $\sigma = 0.5$, $\alpha = 1$
- Sinal de referência: $r(t) = 3 + 10sqw(0.1\pi t)$

A partir desta configuração base, foram realizadas as seguintes simulações adicionais:

- Condições iniciais com $y_0 = 10$
- Condições iniciais com $\theta(0) = 0.95 \cdot \theta^*$
- Matriz $R(0) = 2I$
- $\gamma = 50$
- Sinal de referência com componentes senoidais: $r(t) = 3 + 10sqw(0.1\pi t) + \sin(t) + \sin(3t) + \sin(5t)$

Os resultados serão discutidos a seguir, com gráficos de comparação entre a saída do sistema e o modelo, além das estimativas dos parâmetros adaptativos e da evolução dos erros. Cada simulação destacará o impacto da variação considerada sobre o comportamento geral do sistema.

3.1 Simulação #1 - Base




Figura 2: Resultados da Simulação #1

3.2 Simulação #2 - $y_0 = 10$




Figura 3: Resultados da Simulação #2

3.3 Simulação #3 - $\theta(0) = 0.9\theta^*$




Figura 4: Resultados da Simulação #3

3.4 Simulação #4 - $R(0) = 2I$




Figura 5: Resultados da Simulação #4

3.5 Simulação #5 - $\gamma = 50$




Figura 6: Resultados da Simulação #5

3.6 Simulação #6 - $\tau = 50$




Figura 7: Resultados da Simulação #6

3.7 Simulação #7 - $\beta = 1$




Figura 8: Resultados da Simulação #7

3.8 Simulação #8 - $\kappa = 0.01$




Figura 9: Resultados da Simulação #8

3.9 Simulação #9 - $\sigma = 0.05$




Figura 10: Resultados da Simulação #9

3.10 Simulação #10 - $\alpha = 100$




Figura 11: Resultados da Simulação #10

3.11 Simulação #11 - Mudança no Sinal de Referência




Figura 12: Resultados da Simulação #11

4 Discussão dos Resultados

As simulações realizadas permitiram avaliar o desempenho do algoritmo de controle adaptativo M-MRAC combinado com estimação por mínimos quadrados (LS) frente a diferentes condições iniciais e configurações paramétricas. A seguir, discutimos os principais comportamentos observados:

A **Simulação #1 (Base)** serviu como referência para comparação com as demais variações. Observou-se boa capacidade de rastreamento da saída do modelo de referência, rápida convergência dos parâmetros adaptativos e erro de rastreamento próximo de zero ao longo do tempo.

Na **Simulação #2** ($y_0 = 10$), o sistema iniciou com uma saída significativamente diferente da desejada. Ainda assim, o controlador mostrou robustez, com rápida correção do erro inicial e convergência suave, evidenciando a eficácia da estrutura adaptativa frente a perturbações iniciais.

A **Simulação #3** ($\theta(0) = 0,9\theta^*$) investigou o impacto de um valor inicial para o vetor de parâmetros mais próximo do ideal. O sistema demonstrou uma pequena diferença no tempo de convergência dos parâmetros comparado a simulação base.

Ao variar o ganho inicial da matriz de covariância (**Simulação #4** – $R(0) = 2I$), foi possível notar uma influência direta na taxa de convergência dos parâmetros estimados. Valores maiores de $R(0)$ conferem maior confiança inicial ao estimador, promovendo adaptações mais rápidas, porém com maior sensibilidade a ruído.

Aumentando o ganho da lei de adaptação (**Simulação #5** – $\gamma = 50$), o sistema apresentou maior agressividade na correção do erro, o que reduziu o tempo de convergência, mas potencializou oscilações no início da resposta, sugerindo um trade-off entre velocidade e suavidade.

Nas **Simulações #6 a #9**, foram analisados os parâmetros específicos do estimador LS:

- τ (**Simulação #6**): tempos maiores suavizam a atualização do estimador, tornando-o mais robusto, porém menos reativo;
- β (**Simulação #7**): atua como ganho de normalização, influenciando a estabilidade do algoritmo de estimação;
- κ (**Simulação #8**): controla a influência do termo quadrático na métrica de regressão e pode regularizar a convergência;
- σ (**Simulação #9**): introduz um termo de esquecimento exponencial que limita o crescimento do erro de estimação, útil em ambientes com variação dinâmica.

A **Simulação #10** ($\alpha = 100$) testou a influência do ganho α sobre o erro de predição. Ganhos mais altos penalizam mais fortemente erros residuais, o que resultou em uma redução mais rápida do erro de predição, mas também exigiu maior esforço de controle.

Por fim, a **Simulação #11** demonstrou a resposta do sistema a uma **mudança abrupta no sinal de referência**, avaliando a capacidade de readequação do controlador adaptativo. O algoritmo respondeu de forma estável e eficaz, confirmando a robustez da estrutura M-MRAC + LS mesmo em cenários dinâmicos.

No geral, os resultados demonstram que o controle adaptativo com estimador LS é eficiente em rastrear a referência e adaptar seus parâmetros frente a diversas condições, desde que os ganhos sejam bem ajustados. A **tabela-resumo dos subsistemas e ordens**, apresentada na Tabela 1, reforça a complexidade computacional envolvida, sendo o termo dominante $4n^2$, associado ao estimador LS. Assim, há um custo computacional adicional a ser considerado, que pode impactar implementações em tempo real.