

Trabalho N^o 07 - Combined M-MRAC + LS

COE603 - Controle Adaptativo

Caio Cesar Leal Verissimo - 119046624

Leonardo Soares da Costa Tanaka - 121067652

Lincoln Rodrigues Proença - 121076407

Engenharia de Controle e Automação - UFRJ

Rio de Janeiro, Rio de Janeiro, Brasil

Julho de 2025

Conteúdo

1	Descrição do Algoritmo	5
1.1	Introdução ao Algoritmo	5
1.2	Análise de Estabilidade	5
1.3	Resumo do Algoritmo	5
2	Resultados das Simulações	6
3	Discussão dos Resultados	6

Estabilidade do algoritmo Combined MRAC

Modelo da Planta e do Modelo de Referência

$$\dot{y} = -a_p y + k_p u \quad (1)$$

$$\dot{y}_m = -a_m y_m + k_m r, \quad a_m > 0 \quad (2)$$

$$e = y - y_m \quad (3)$$

Regressor:

$$\omega = \begin{bmatrix} y & r \end{bmatrix}^T \quad (4)$$

Parâmetros estimados de controle:

$$\theta = \begin{bmatrix} \theta_1 & \theta_2 \end{bmatrix}^T \quad (5)$$

Lei de controle:

$$u = \theta^T \omega \quad (6)$$

Parâmetros correspondentes ideais:

$$\theta_1^* = \frac{a_p - a_m}{k_p} \quad (7)$$

$$\theta_2^* = \frac{k_m}{k_p} \quad (8)$$

Estimador Composto M-MRAC + LS

Parâmetros estimados da planta:

$$\psi = \begin{bmatrix} \psi_1 & \psi_2 \end{bmatrix}^T \quad (9)$$

Parâmetros correspondentes ideais:

$$\psi^* = \begin{bmatrix} a_p & k_p \end{bmatrix}^T \quad (10)$$

Modelo de identificação:

$$\dot{\hat{y}} = -a_i \epsilon + \psi_1 y + \psi_2 u, \quad a_i > 0 \quad (11)$$

Erro de identificação:

$$\epsilon = y - \hat{y} \quad (12)$$

Relações algébricas:

$$\psi_2^* \theta_1^* - \psi_1^* + a_m = 0 \quad (13)$$

$$\psi_2^* \theta_2^* - k_m = 0 \quad (14)$$

Equações dos erros (não lineares):

$$\Delta_1 = \psi_2 \theta_1 - \psi_1 + a_m \quad (15)$$

$$\Delta_2 = \psi_2 \theta_2 - k_m \quad (16)$$

$$\dot{e} = -a_m e + k_p \tilde{\theta}^T \omega \quad (17)$$

Equação de identificação:

$$\dot{\epsilon} = -a_i \epsilon + \tilde{\psi}_1 y + \tilde{\psi}_2 u \quad (18)$$

Leis de Atualização

Controle:

$$\dot{\theta} = -\text{sign}(k_p)[\gamma_1 e \omega + \gamma_2 \Delta] \quad (19)$$

Identificação:

$$\dot{\psi}_1 = \kappa_1 \epsilon y + \kappa_2 \Delta_1 \quad (20)$$

$$\dot{\psi}_2 = \kappa_1 \epsilon u - \kappa_2 \theta^T \Delta \quad (21)$$

Reescrevendo as Funções Δ

$$\Delta_1 = \psi_2 \theta_1 - \psi_1 + a_m - (\psi_2^* \theta_1^* - \psi_1^* + a_m) \quad (22)$$

$$= \psi_2 \theta_1 - (\psi_1 - \psi_1^*) - k_p (\theta_1 - \tilde{\theta}_1) \quad (23)$$

$$= \theta_1 \tilde{\psi}_2 - \tilde{\psi}_1 + k_p \tilde{\theta}_1 \quad (24)$$

$$\Delta_2 = \psi_2 \theta_2 - k_m - (\psi_2^* \theta_2^* - k_m) \quad (25)$$

$$= \psi_2 \theta_2 - k_p (\theta_2 - \tilde{\theta}_2) \quad (26)$$

$$= \theta_2 \tilde{\psi}_2 + k_p \tilde{\theta}_2 \quad (27)$$

Análise de Estabilidade pelo Método de Lyapunov

Seja a seguinte função de Lyapunov candidata:

$$V = \frac{\gamma_1}{2\gamma_2} e^2 + \frac{|k_p|}{\gamma_2} \tilde{\theta}^T \tilde{\theta} + \frac{\kappa_1}{2\kappa_2} \epsilon^2 + \frac{1}{\kappa_2} \tilde{\psi}^T \tilde{\psi} \quad (28)$$

Ela é positiva definida, pois cada termo representa um quadrado ponderado por constantes positivas. Derivando V no tempo, temos:

$$\dot{V} = \frac{\gamma_1}{\gamma_2} e \dot{e} + \frac{2|k_p|}{\gamma_2} \tilde{\theta}^T \dot{\theta} + \frac{\kappa_1}{\kappa_2} \epsilon \dot{\epsilon} + \frac{2}{\kappa_2} \tilde{\psi}^T \dot{\psi}$$

Derivada do erro de rastreamento e :

$$\dot{e} = -a_m e + k_p \tilde{\theta}^T \omega \quad \Rightarrow \quad \frac{\gamma_1}{\gamma_2} e \dot{e} = -\frac{\gamma_1}{\gamma_2} a_m e^2 + \frac{\gamma_1}{\gamma_2} k_p e \tilde{\theta}^T \omega$$

Lei de adaptação de θ :

$$\dot{\theta} = -\text{sign}(k_p) [\gamma_1 e \omega + \gamma_2 \Delta] \quad \Rightarrow \quad \tilde{\theta}^T \dot{\theta} = -\text{sign}(k_p) \gamma_1 e \tilde{\theta}^T \omega - \text{sign}(k_p) \gamma_2 \tilde{\theta}^T \Delta$$

Logo:

$$\frac{2|k_p|}{\gamma_2} \tilde{\theta}^T \dot{\theta} = -2 \frac{\gamma_1}{\gamma_2} k_p e \tilde{\theta}^T \omega - 2 k_p \tilde{\theta}^T \Delta$$

Derivada do erro de identificação ϵ :

$$\dot{\epsilon} = -a_i \epsilon + \tilde{\psi}^T \phi \quad \text{com} \quad \phi = \begin{bmatrix} y \\ u \end{bmatrix} \quad \Rightarrow \quad \frac{\kappa_1}{\kappa_2} \epsilon \dot{\epsilon} = -\frac{\kappa_1}{\kappa_2} a_i \epsilon^2 + \frac{\kappa_1}{\kappa_2} \epsilon \tilde{\psi}^T \phi$$

Lei de adaptação de ψ :

$$\dot{\psi} = \kappa_1 \epsilon \phi + \kappa_2 \begin{bmatrix} \Delta_1 \\ -\theta^T \Delta \end{bmatrix} \quad \Rightarrow \quad \tilde{\psi}^T \dot{\psi} = \kappa_1 \epsilon \tilde{\psi}^T \phi + \kappa_2 \tilde{\psi}_1 \Delta_1 - \kappa_2 \tilde{\psi}_2 \theta^T \Delta$$

Logo:

$$\frac{2}{\kappa_2} \tilde{\psi}^T \dot{\psi} = 2 \epsilon \tilde{\psi}^T \phi + 2 \tilde{\psi}_1 \Delta_1 - 2 \tilde{\psi}_2 \theta^T \Delta$$

Somando os termos:

$$\begin{aligned} \dot{V} = & -\frac{\gamma_1}{\gamma_2} a_m e^2 - 2 \gamma_1 e \tilde{\theta}^T \omega + \frac{\gamma_1}{\gamma_2} k_p e \tilde{\theta}^T \omega + 2 |k_p| \tilde{\theta}^T \Delta \\ & - \frac{\kappa_1}{\kappa_2} a_i \epsilon^2 + \frac{\kappa_1}{\kappa_2} \epsilon \tilde{\psi}^T \phi + 2 \epsilon \tilde{\psi}^T \phi + 2 \tilde{\psi}_1 \Delta_1 - 2 \tilde{\psi}_2 \theta^T \Delta \end{aligned}$$

Agrupando os termos de Δ :

$$2 |k_p| \tilde{\theta}^T \Delta + 2 \tilde{\psi}_1 \Delta_1 - 2 \tilde{\psi}_2 \theta^T \Delta = 2 \Delta^T \Delta$$

Assim, a derivada total resulta em:

$$\dot{V} = -\frac{\gamma_1}{\gamma_2} a_m e^2 - \frac{\kappa_1}{\kappa_2} a_i \epsilon^2 - \Delta^T \Delta \leq 0$$

Logo, pelo Teorema de Lyapunov Direto, o sistema é **estável no sentido de Lyapunov**.

Observação sobre Convergência: Para garantir a **convergência assintótica** dos erros, é necessário aplicar o Teorema de LaSalle. Como $\dot{V} = 0$ implica que $e = 0$, $\epsilon = 0$ e $\Delta = 0$, sob persistência de excitação, conclui-se que os parâmetros estimados convergem para seus valores ideais.

1 Descrição do Algoritmo

1.1 Introdução ao Algoritmo

1.2 Análise de Estabilidade

1.3 Resumo do Algoritmo

Subsistema	Equação	Ordem
Planta	$y = P(s) u$	n
Modelo	$y_m = M(s) r$	n
Erro de rastreamento	$e_a = \text{sign}(k_p)(y - y_m)$	
Filtros SV	$\dot{\omega}_1 = A_f \omega_1 + b_f u$ $\dot{\omega}_2 = A_f \omega_2 + b_f y$	$n - 1$
Regressor	$\omega^T = [\omega_1^T \quad y \quad \omega_2^T \quad r]$	
Filtro ξ	$\dot{\xi} = -\ell_0 \xi + \omega, \quad \ell_0 > a_m$	$2n$
Lei de controle	$u = \theta^T \omega + \hat{\theta}^T \xi$	
Lei de adaptação	$\dot{\theta} = -\Gamma \xi e_a - \sigma \Delta, \quad \Gamma = \Gamma^T > 0, \quad \sigma > 0$ $\Delta = \theta - \psi$	$2n$
Filtros auxiliares	$\dot{\zeta} = -\ell_0 \zeta + u$ $\dot{\varphi} = -\ell_0 \varphi + e_0$	1
Predição	$\hat{\zeta} = \psi^T \phi$ $\phi = \xi + [\mathbf{0}^T \quad (e_0 - \alpha \varphi)]^T, \quad \mathbf{0} \in \mathbb{R}^{2n-1}$	
Erro de predição	$\varepsilon = \hat{\zeta} - \zeta$	
Estimador LS	$\dot{\psi} = -R \left(\tau \phi \varepsilon - \frac{\sigma}{\beta} \Gamma^{-1} \Delta \right), \quad \tau > \frac{1}{2}, \quad \beta > 0$ $\dot{R} = -\frac{R \phi \phi^T R}{m^2}, \quad R(0) = R^T(0) > 0$ $m^2 = 1 + \kappa \phi^T R \phi, \quad \kappa \geq 0$	$2n$ $4n^2$

Tabela 1: Resumo dos subsistemas, equações e ordens no controle adaptativo

Dimensão total do sistema: $N = 10n + 4n^2$

2 Resultados das Simulações

3 Discussão dos Resultados